Analyse Numérique
Cours de Licence : SMP4
2024-2025

Chapitre 4: Systèmes d'équations algébriques

Benmoussa Khalid

Faculté des Sciences Agadir, Université Ibn-Zohr

2024-2025

De nombreuses méthodes numériques conduisent à la résolution d'un système matriciel de la forme

$$Ax = b.$$

L'inconnue est le vecteur x, tandis que la matrice A et le second membre b sont connus. Le but de ce chapitre est de voir des méthodes de résolution «automatique»

des systèmes, qui soient le plus efficace possible. Aujourd'hui, la taille du vecteur x,

représentant les inconnues, dépasse souvent les milliers, et peut même dépasser le milliard d'inconnues !

$\rightarrow$ Que peut représenter ce vecteur x en pratique ?

Moralité : Il est aujourd'hui très courant de traiter des problèmes de grandes tailles !
Plan de bataille du chapitre :

- Étude des systèmes dit linéaires (élimination de Gauss, factorisation LU, Cholesky)
- Normes et conditionnement de matrices,
- Généralisation de la méthode de Newton pour résoudre les systèmes d'équations non linéaires.

Pour les systèmes linéaires, nous allons uniquement étudier les **méthodes dites directes**, i.e donnant la solution en un nombre fini et prédéterminé d'opérations. Des **méthodes itératives**, nécessitant en théorie un nombre infinie d'opérations, existent également pour résoudre ces systèmes. Pour les systèmes d'équations non-linéaires, l'utilisation de méthodes itératives devient obligatoire.

De manière générale, un système de m **équations linéaires** à n inconnues, est un système pouvant être écrit sous la forme suivante :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \cdots + a_{3n}x_n = b_3 \\ \vdots \qquad\qquad \vdots \qquad\qquad \vdots \\ a_{m1}x_1 + a_{m2}x_2 + a_{m3}x_3 + \cdots + a_{mn}x_n = b_m \end{cases} \tag{1}$$

où $x_1, x_2, \cdots, x_n$ sont **les inconnues** et les a_{ij} **les coefficients** du système.
Pour le cours, **on aura $n = m$**, *i.e.* autant d'inconnues que d'équations.
On étudiera donc les systèmes où la matrice A est carrée. Le système (6), où

$m = n$, s'écrit sous la forme matricielle $Ax = b$

$$\underbrace{\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}}_{A} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}}_{x} = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}}_{b}$$

En pratique, la matrice A et le second membre b seront connus, il s'agira de déterminer le vecteur $x = (x_1, x_2, \cdots, x_n)$. **Rappel :** Les propositions équivalentes

suivantes garantissent l'existence d'une solution au système matriciel

- La matrice A est inversible, *i.e.* A^{-1} existe ($AA^{-1} = A^{-1}A = I$),
- Le déterminant de la matrice A, noté det(A) est non nul,
- La matrice A est de rang maximal (nombre d'inconnues=nombre d'équations).

Dans ce chapitre, on traitera les cas où l'une de propositions ci-dessus est vérifiée, *i.e.* A inversible (non singulière), on écrira $x = A^{-1}b$. n pratique, on ne calculera jamais

explicitement A^{-1}. Calculer l'inverse d'une matrice n'est pas numériquement efficace! On va plutôt travailler sur le système linéaire de départ afin de déterminer x. Comment résoudre de manière systématique un système linéaire ?

Regardons d'abord un cas particulier de matrices, les matrices diagonales.

Definition

"Matrice diagonale" La matrice $A = (a_{ij})_{1 \leq i,j \leq n}$ est dite **diagonale**, si ses entrées sont nulles en dehors de sa diagonale (i.e. si $i \neq j$ alors $a_{ij} = 0$). Une telle matrice est de la forme

$$A = \begin{pmatrix} a_{11} & 0 & \dots & \dots & 0 \\ 0 & a_{22} & \ddots & & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \vdots & & \ddots & \ddots & 0 \\ 0 & \dots & \dots & 0 & a_{nn} \end{pmatrix}$$

on a alors, $\det(A) = a_{11} \times a_{22} \times \dots \times a_{nn} = \prod_{i=1}^{n} a_{ii}$

Dans ce cas, la résolution du système $Ax = b$ est immédiate,

$$x_i = \frac{b_i}{a_{ii}}, \ i = 1, \cdots, n$$

Definition

"Matrice triangulaire" La matrice $A = (a_{ij})_{1 \leq i,j \leq n}$ est dite **triangulaire inférieure** si tous les a_{ij} sont nuls pour $i < j$. Une matrice triangulaire inférieure est donc de la forme

$$A = \begin{pmatrix} a_{11} & 0 & 0 & 0 & \dots & 0 \\ a_{21} & a_{22} & 0 & 0 & \dots & 0 \\ a_{31} & a_{32} & a_{33} & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n-1\,1} & a_{n_1\,2} & a_{n-1\,3} & \dots & a_{n-1\,n-1} & 0 \\ a_{n\,1} & a_{n\,2} & a_{n\,3} & \dots & a_{n\,n-1} & a_{n\,n} \end{pmatrix}$$

Une matrice est dite **triangulaire supérieure** si tous les a_{ij} sont nuls pour $j < i$ (transposée d'une matrice triangulaire inférieure). Dans les deux cas, $\det(A) = a_{11} \times a_{22} \times \dots \times a_{nn} = \prod_{i=1}^{n} a_{ii}$

La résolution du système $Ax = b$ avec A triangulaire inférieure ou supérieure est également aisée. On effectue une **descente triangulaire** ou **remontée triangulaire**, selon le cas.

- A triangulaire inférieure $\rightarrow$ descente triangulaire

$$x_1 = \frac{b_1}{a_{11}}, \quad x_i = \frac{\left(b_i - \sum_{k=1}^{i-1} a_{ik} x_k\right)}{a_{ii}}, \; i = 2, 3, \cdots, n. \tag{2}$$

- A triangulaire supérieure $\rightarrow$ remontée triangulaire

$$x_n = \frac{b_n}{a_{nn}}, \quad x_i = \frac{\left(b_i - \sum_{k=i+1}^{n} a_{ik} x_k\right)}{a_{ii}}, \; i = n-1, n-2, \cdots, 2, 1. \tag{3}$$

attention

Les formules (2) et (3) sont valides si les a_{ii} sont tous non nuls. Dans le cas contraire, cela signifie que $\det(A) = 0$ est donc que la matrice n'est pas inversible. Le système $Ax = b$ n'admet alors pas de solution unique.

Combien coûte (en nombre d'opérations) une descente (resp. remontée) triangulaire ?

- $\sum_{i=1}^{n} i = \frac{n(n+1)}{2}$ multiplications/divisions $\rightarrow O(n^2)$
- $\sum_{i=1}^{n-1} i = \frac{n(n-1)}{2}$ additions/soustractions $\rightarrow O(n^2)$

Les méthodes de descentes et remontées triangulaires sont très génériques, mais nécessitent que A soit triangulaire. L'idée va donc être de transformer une matrice

carrée quelconque en matrice triangulaire.

$\rightarrow$ **Élimination de Gauss**

L'élimination de Gauss consiste à effectuer des opérations élémentaires sur les lignes de la matrice A. **But :** Introduire des zéros sous la diagonale de la matrice A afin de la

rendre triangulaire supérieure. On note l_i la ligne i de la matrice A. Les trois

opérations élémentaires sont les suivantes :

- $(l_i \leftarrow \lambda l_i)$: remplacer la ligne i par un multiple d'elle-même,
- $(l_i \leftrightarrow l_j)$: intervertir la ligne i et j,
- $(l_i \leftarrow l_i + \lambda l_j)$: remplacer la ligne i par la ligne i plus un multiple de la ligne j.

Chacune de ces opérations revient à multiplier la matrice A par une matrice inversible W. **Remarque :** En multipliant par une telle matrice inversible W, la solution du

système de départ n'est pas modifiée

$$WAx = Wb \iff W^{-1}WAx = W^{-1}b \iff Ax = b$$

- $(l_i \leftarrow \lambda l_i)$: W est une matrice ressemblant à la matrice identité, sauf pour le coefficient W_{ii} qui vaut λ,
- $(l_i \leftrightarrow l_j)$: W est une matrice où la ligne i et la ligne j de la matrice identité sont permutées,
- $(l_i \leftarrow l_i + \lambda l_j)$: W est une matrice ressemblant à la matrice identité, sauf pour le coefficient W_{ij} qui vaut λ.

En pratique, dans l'élimination de Gauss, on ne multiplie pas par les matrices W, on fait plutôt les opérations élémentaires sur la matrice dite augmentée, *i.e* la matrice que l'on obtient en ajoutant le membre de droite b à la matrice A, c'est-à-dire :

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} & b_n \end{pmatrix}$$

Les opérations élémentaires sont faites **à la fois sur la matrice A et le second membre b**.

Une fois la matrice A rendu triangulaire supérieure, il ne reste plus qu'à effectuer une remontée triangulaire afin d'obtenir la solution x. Avantage : permet de traiter des

matrices quelconques, Inconvénient : si l'on change le second membre b, on doit tout

recommencer ! Dans l'élimination de Gauss, on effectue les opérations directement

sur A et b, les matrices des opérations élémentaires ne sont pas conservées. $\rightarrow$ On

«jette» de l'information en effectuant l'élimination de Gauss ! La solution va être de

conserver ces matrices.

Soit $T = W_N W_{N-1} \cdots W_1$ la matrice représentant la suite d'opérations élémentaires rendant la matrice A triangulaire supérieure. Cette matrice ne dépend pas de b et l'on a

$$TAx = Tb$$

Posons $U = TA$, U est la matrice triangulaire supérieure, et

$$T^{-1}Ux = T^{-1}Tb = b$$

Autrement dit, $T^{-1}U = A$, et posons

$$L = T^{-1} = (W_N W_{N-1} \cdots W_1)^{-1} = W_1^{-1} W_2^{-1} \cdots W_N^{-1}$$

L est la matrice triangulaire inférieure qui a permis d'éliminer les termes non nuls sous la diagonale de la matrice A dans l'élimination de Gauss.

Theorem

"Décomposition LU" Si $A \in M_n(\mathbb{R})$, telle que les sous matrices d'ordre $1 \leq k \leq n$ (sous matrices principales) :

$$A^k = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1k} \\ a_{21} & a_{22} & \dots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \dots & a_{kk} \end{pmatrix}$$

soient inversibles ($\det(A^k) \neq 0, 1 \leq k \leq n$). *Alors il existe une matrice triangulaire supérieure U («Upper»), et une matrice triangulaire inférieure L («Lower»), telle que*

$$A = LU$$

Si l'on fixe la diagonale de L (ou de U) avec des 1, la décomposition est unique.

On a donc le choix dans la matrice où l'on place les 1 sur la diagonale. **La factorisation** LU **sera différente** suivant que l'on place les 1 sur la diagonale de L ou la diagonale de U.

En quoi cela nous aide-t-il à résoudre $Ax = b$?

$$Ax = b \iff LUx = b$$

Posons $Ux = y$. **La résolution de $Ax = b$ se fait alors en deux étapes :**

1. Résoudre, par une descente, $Ly = b \quad (\rightarrow y)$
2. Résoudre, par une remontée, $Ux = y \quad (\rightarrow x)$

C'est la **méthode de résolution par décomposition LU. Remarques :**

- Si l'on change le second membre b, on peut réutiliser la factorisation LU de la matrice A. Il suffira à nouveau d'effectuer une descente puis une remontée pour trouver x,
- L'hypothèse $\det(A^k) \neq 0$ permet de s'assurer qu'il n'y aura pas de pivots nuls pendant la décomposition,
- Lorsque les 1 sont sur la diagonale de L ($L_{ii} = 1$), il s'agit de la **décomposition de Doolittle** (ce que fait Matlab par défaut). Lorsque les 1 sont sur la diagonale de U ($U_{ii} = 1$), il s'agit de la **décomposition de Crout**.

Que faire en cas de pivots nuls ? → On réalise une **permutation des lignes**. Cela permet alors d'avoir un théorème un peu plus général.

Theorem

"Décomposition PA=LU" Soit A une matrice inversible. Il existe P une matrice produit de matrice de permutations, L triangulaire inférieure et U triangulaire supérieure telles que :

$$PA = LU, \text{ avec } |\det(P)| = 1$$

En pratique :

- Une permutation de ligne est toujours faite avant de faire les opérations pour annuler les termes de la colonne.
- Même lorsque les permutations de lignes ne sont pas «nécessaire», il est courant d'en réaliser afin que le pivot (l_{ii} ou u_{jj}) soit de valeur absolue la plus grande possible.

Voyons comment déterminer de façon automatique les matrices L et U, pour en tirer un algorithme implémentable.

Algorithme de décomposition LU (Crout) : Supposons connues les $j-1$ premières colonnes de L et les $j-1$ premières lignes de U, on veut calculer la ligne j de U et la colonne j de L

- Calcul du pivot :

$$l_{jj} = a_{jj} - \sum_{k=1}^{j-1} l_{jk}\, u_{kj}$$

- Calcul de la colonne j de L pour $j+1 \leq i \leq n$:

$$l_{ij} = a_{ij} - \sum_{k=1}^{j-1} l_{ik}\, u_{kj}$$

- Calcul de la ligne j de U pour $j+1 \leq i \leq n$:

$$u_{ji} = \frac{1}{l_{jj}} \left(a_{ji} - \sum_{k=1}^{j-1} l_{jk}\, u_{ki} \right)$$

Je vous déconseille fortement de retenir ces formules !

Il suffit d'écrire ce que l'on «veut». Exemple sur une matrice 4×4 et la décomposition de Crout.

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix} \begin{pmatrix} 1 & u_{12} & u_{13} & u_{14} \\ 0 & 1 & u_{23} & u_{24} \\ 0 & 0 & 1 & u_{34} \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{pmatrix}$$

1. Première colonne de L : (lignes de L) $\times$ (première colonne de U)

$$l_{11} = a_{11}, \quad l_{21} = a_{21}, \quad l_{31} = a_{31}, \quad l_{41} = a_{41}. \tag{4}$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

2. Première ligne de U : (première ligne de L) $\times$ (colonnes de U)

$$l_{11}u_{12} = a_{12} \Rightarrow u_{12} = a_{12}/l_{11}, \quad u_{13} = a_{13}/l_{11}, \quad u_{14} = a_{14}/l_{11},$$

$$\begin{pmatrix} 1 & u_{12} & u_{13} & u_{14} \\ 0 & 1 & u_{23} & u_{24} \\ 0 & 0 & 1 & u_{34} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

3. Deuxième colonne de L : (lignes de L) $\times$ deuxième colonne de U

$$l_{22} = a_{22} - l_{21}u_{12}, \quad l_{32} = a_{32} - l_{31}u_{12}, \quad l_{42} = a_{42} - l_{41}u_{12}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

4. Deuxième ligne de U : (deuxième ligne de L) $\times$ (colonnes de U)

$$u_{23} = (a_{23} - l_{21}u_{13})/l_{22}, \quad u_{24} = (a_{24} - l_{21}u_{14})/l_{22}.$$

$$\begin{pmatrix} 1 & u_{12} & u_{13} & u_{14} \\ 0 & 1 & u_{23} & u_{24} \\ 0 & 0 & 1 & u_{34} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

5. Troisième colonne de L : (lignes de L) $\times$ troisième colonne de U

$$l_{33} = a_{33} - l_{31}u_{13} - l_{32}u_{23}, \quad l_{43} = a_{43} - l_{41}u_{13} - l_{42}u_{23}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

6. Troisième ligne de U : (troisième ligne de L) $\times$ (quatrième colonne de U)

$$u_{34} = (a_{34} - l_{31}u_{14} - l_{32}u_{24})/l_{33}.$$

$$\begin{pmatrix} 1 & u_{12} & u_{13} & u_{14} \\ 0 & 1 & u_{23} & u_{24} \\ 0 & 0 & 1 & u_{34} \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

7. Quatrième colonne de L : (lignes de L) $\times$ (quatrième colonne de U)

$$l_{44} = a_{44} - l_{41}u_{14} - l_{42}u_{24} - l_{43}u_{34}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

Pour limiter l'espace mémoire utilisé, la décomposition LU peut être stockée dans la matrice A (la matrice A est détruite au cours de l'opération).

Definition

"LU compacte" La matrice LU compacte est la matrice :

$$\begin{pmatrix} l_{11} & u_{12} & u_{13} & \dots & u_{1n} \\ l_{21} & l_{22} & u_{23} & \dots & u_{2n} \\ l_{31} & l_{32} & l_{33} & \dots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \dots & l_{nn} \end{pmatrix}$$

Nombre d'opérations pour la décomposition LU

- nombre d'additions/soustractions : $\frac{2n^3-3n^2+n}{6} \rightarrow O(\frac{2n^3}{6})$
- nombre de divisions/multiplications : $\frac{n^3-n}{3} \rightarrow O(\frac{n^3}{3})$

Nombre d'opérations pour les remontées

- nombre d'additions/soustractions : $n^2 - n \rightarrow O(n^2)$
- nombre de divisions/multiplications : $n^2 \rightarrow O(n^2)$

Remarque : La décomposition LU permet de calculer facilement le déterminant de A, pour la décomposition de Crout, on aura :

$$\det(A) = \det(L)\det(U) = \det(L) = \prod_{i=1}^{n} l_{ii}$$

Et pour Doolittle,

$$\det(A) = \det(L)\det(U) = \det(U) = \prod_{i=1}^{n} u_{ii}$$

ême si la matrice A est une matrice creuse, *i.e* une matrice comportant de nombreux zéros, il n'y a aucune raison que la matrice compacte résultant de la factorisation LU soit également creuse.

Definition

"Matrice à diagonale strictement dominante" Une matrice A est à **diagonale strictement dominante** par lignes si :

$$\forall i, |a_{ii}| > \sum_{j=1, j\neq i}^{n} |a_{ij}|$$

ou par colonnes si :

$$\forall j, |a_{jj}| > \sum_{i=1, i\neq j}^{n} |a_{ij}|$$

Theorem

Si A est à diagonale strictement dominante par colonne ou par ligne :

- *A est inversible.*
- *L'élimination de Gauss et la décomposition LU se font sans permuter de lignes*

Conclusion factorisation LU :

- Si $\det(A) = 0$, le système n'a pas de solution unique,
- Peu efficace pour n grand,
- Si tous les déterminants des sous-matrices principales A^k de A **sont non nuls, alors la décomposition n'exige pas de permutations.** De même si A est à diagonale strictement dominante,
- Si on a seulement A inversible ($\det(A) \neq 0$) alors on a l'existence d'une décomposition de la forme $PA = LU$, avec P une matrice de permutation.
- En pratique, on stocke la factorisation directement dans la matrice A. Attention, il est possible que la factorisation LU prenne plus de place en mémoire que la matrice A elle-même!

Chapitre 4 : Systèmes d'équations algébriques - Factorisation de Cholesky

Voyons à présent la décomposition pour un type particulier de matrice.

Definition

"Matrice Symétrique Définie Positive (SDP)" Soit A une matrice symétrique ($A = A^t$). A est dite définie positive si

$$Ax \cdot x = x^t Ax > 0, \quad \forall x \neq 0$$

Theorem

"Factorisation de Cholesky" Soit A une ***matrice symétrique****, les propositions suivantes sont équivalentes :*

- *A est définie positive,*
- *Les déterminants de toutes les sous matrices principales A^k de A sont* ***strictement positifs****,*
- *(les valeurs propres de A sont réelles et strictement positives),*
- *Il existe une factorisation dite de* ***Cholesky*** *de A : $\mathbf{A = LL^t}$, L étant une matrice triangulaire inférieure dont les termes sur la diagonale (l_{ii}) sont strictement positifs.*

En pratique, on cherche donc une matrice L, triangulaire inférieure telle que

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix} \begin{pmatrix} l_{11} & l_{21} & l_{31} & l_{41} \\ 0 & l_{22} & l_{32} & l_{42} \\ 0 & 0 & l_{33} & l_{43} \\ 0 & 0 & 0 & l_{44} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \end{pmatrix}$$

Comme pour LU, on détermine les coefficients de L.

1. Première colonne de L

$$l_{11} = \sqrt{a_{11}}, \quad l_{21} = \frac{a_{21}}{l_{11}}, \quad l_{31} = \frac{a_{31}}{l_{11}}, \quad l_{41} = \frac{a_{41}}{l_{11}}. \tag{5}$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

3. Deuxième colonne de L

$$l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{32} = \frac{a_{32} - l_{31} l_{21}}{l_{22}}, \quad l_{42} = \frac{a_{42} - l_{41} l_{21}}{l_{22}}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

4. Troisième colonne de L

$$l_{33} = \sqrt{a_{33} - l_{31}^2 - l_{32}^2}, \quad l_{43} = \frac{a_{43} - l_{41}l_{31} - l_{42}l_{32}}{l_{33}}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

6. Quatrième colonne de L

$$l_{44} = \sqrt{a_{44} - l_{41}^2 - l_{42}^2 - l_{43}^2}.$$

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 \\ l_{41} & l_{42} & l_{43} & l_{44} \end{pmatrix}$$

Remarques :

- Si $A = LL^t$, alors $\det(A) = \det(L)\det(L^t) = \det(L)^2 = \left(\Pi_{i=1}^{n} l_{ii}\right)^2$
- La condition $l_{ii} > 0$ dans le théorème précédent, sert à assurer l'unicité de la factorisation,
- On ne construit et ne stocke qu'une matrice triangulaire inférieure L,
- La résolution de $Ax = b$ se fait toujours en deux étapes, comme pour LU. Seule l'étape de décomposition coûte moins cher.

attention

Il faut bien faire attention à vérifier les hypothèses du théorème avant d'effectuer la décomposition de Cholesky, i.e vérifier que A est symétrique et définie positive.

Avant de se lancer dans les calculs pour voir si une matrice est «Choleskysable», peut-on éliminer d'office certaines matrices ? Supposons que A est «Choleskysable»,

alors A est symétrique et $A = LL^t$

$$\Rightarrow a_{ii} = \sum_{k=1}^{n} l_{ik}^2 > 0$$

Autrement dit, si la matrice A possède au moins un coefficient négatif sur sa diagonale, alors la décomposition de Cholesky ne sera pas applicable.

proposition

*Soit A une matrice **symétrique** et a **diagonale strictement dominante**, dont les **termes diagonaux sont strictement positifs**, alors A admet une factorisation de Cholesky.*

attention

Si la matrice A ne vérifie pas les conditions de la proposition, on ne peut rien conclure. Ce sont des conditions suffisantes mais pas nécessaires.

Exemple :

On considère la matrice $A = \begin{pmatrix} 4 & 2 & 0 & 6 \\ 2 & 10 & 6 & 6 \\ 0 & 6 & 20 & 10 \\ 6 & 6 & 10 & 18 \end{pmatrix}$

1. Montrer que A admet une décomposition de Cholesky LL^t .
2. Calculer la décomposition LL^t de Cholesky.
3. Résoudre le système linéaire $Ax = b$, où A est la matrice ci-dessus, en utilisant la décomposition LL^t, avec

$$b = \begin{pmatrix} 22 \\ 32 \\ 22 \\ 48 \end{pmatrix}$$

1. puisque les déterminants des sous matrices principales sont strictement positifs, alors la matrice A admet une décomposition de Cholesky LL^t :

$$\det A = \begin{pmatrix} 4 & 2 & 0 & 6 \\ 2 & 10 & 6 & 6 \\ 0 & 6 & 20 & 10 \\ 6 & 6 & 10 & 18 \end{pmatrix} = 2304 \text{ , } \det \begin{pmatrix} 4 & 2 & 0 \\ 2 & 10 & 6 \\ 0 & 6 & 20 \end{pmatrix} = 576 \text{ , } \det \begin{pmatrix} 4 & 2 \\ 2 & 10 \end{pmatrix} = 36$$

2. la représentation matricielle $Ax = b$

$$\begin{bmatrix} 4 & 2 & 0 & 6 \\ 2 & 10 & 6 & 6 \\ 0 & 6 & 20 & 10 \\ 6 & 6 & 10 & 18 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 22 \\ 32 \\ 22 \\ 48 \end{bmatrix}$$

3. A est une matrice symétrique définie positive car les déterminants des sous matrices sont strictement positifs donc elle admet une factorisation de Cholesky.

1. $L_{11} = \sqrt{A_{11}} = 2$

   $L_{i1} = \frac{A_{i1}}{L_{11}}, \quad i = 2 \cdots 4, \quad L_{21} = 1, \quad L_{31} = 0, \quad L_{41} = 3$

   $L_{22} = \sqrt{A_{22} - L_{21}^2} = \sqrt{10 - 1^2} = 3$

   $L_{32} = \frac{A_{32} - L_{31} L_{21}}{L_{22}} = \frac{6 - 0 \times 1}{3} = 2$

   $L_{42} = \frac{A_{42} - L_{41} L_{21}}{L_{22}} = \frac{6 - 3 \times 1}{3} = 1$

   $L_{33} = \sqrt{A_{33} - L_{31}^2 - L_{32}^2} = \sqrt{20 - 0^2 - 2^2} = 4$

   $L_{43} = \frac{A_{43} - L_{41} L_{31} - L_{42} L_{32}}{L_{33}} = \frac{10 - 3 \times 0 - 1 \times 2}{4} = 2$

   $L_{44} = \sqrt{A_{44} - L_{41}^2 - L_{42}^2 - L_{43}^2} = \sqrt{18 - 3^2 - 1^2 - 2^2} = 2$

La matrice L est donnée par :

$$L=\begin{bmatrix}2 & 0 & 0 & 0\\ 1 & 3 & 0 & 0\\ 0 & 2 & 4 & 0\\ 3 & 1 & 2 & 2\end{bmatrix}$$

Résoudre le système $Ax = b \Longrightarrow LL^t x = b$

On pose $L^t x = y$

On résout premièrement $Ly = b$:

$$\begin{bmatrix}2 & 0 & 0 & 0\\ 1 & 3 & 0 & 0\\ 0 & 2 & 4 & 0\\ 3 & 1 & 2 & 2\end{bmatrix}\begin{bmatrix}y_1\\ y_2\\ y_3\\ y_4\end{bmatrix}=\begin{bmatrix}22\\ 32\\ 22\\ 48\end{bmatrix}$$

Par la descente triangulaire, on obtient : $y_1 = 11$

$y_1 + 3y_2 = 32 \Longrightarrow y_2 = 7$

$2y_2 + 4y_3 = 22 \Longrightarrow y_3 = 2$

$3y_1 + y_2 + 2y_3 + 2y_4 = 48 \Longrightarrow y_4 = 2$

On résout deuxièmement $L^t x = y$:

$$\begin{bmatrix} 2 & 1 & 0 & 3 \\ 0 & 3 & 2 & 1 \\ 0 & 0 & 4 & 2 \\ 0 & 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 11 \\ 7 \\ 2 \\ 2 \end{bmatrix}$$

Par la remontée triangulaire, on obtient :

$2x_4 = 2 \Longrightarrow x_4 = 1$

$4x_3 + 2x_4 = 2 \Longrightarrow x_3 = 0$

$3x_2 + 2x_3 + x_4 = 7 \Longrightarrow x_2 = 2$

$2x_1 + x_2 + 3x_4 = 11 \Longrightarrow x_1 = 3$

La solution est :$x = (3, 2, 0, 1)^t$

La résolution numérique des grands systèmes linéaires peut parfois nécessiter l'emploi de méthodes autres que la décomposition *LU* qui requiert la mise en mémoire d'une matrice de très grande taille. Les méthodes itératives, en revanche, permettent de ne placer en mémoire que les coefficients non nuls d'une matrice. La convergence des méthodes itératives n'est réalisée que dans certaines conditions que nous préciserons. On n'observe l'avantage que dans les systèmes linéaires de très grande taille.
dans la suite on traite deux méthodes itératives :

1. Méthode de Jacobi
2. Méthode de Gauss-Seidel

On considére le système linéaire :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = b_2 \\ \vdots \qquad\qquad \vdots \qquad\qquad \vdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \cdots + a_{nn}x_n = b_n \end{cases} \tag{6}$$

où $a_{ii} \neq 0 \quad \forall i$. Nous partons d'une solution initiale $[x_1^0 x_1^0 \cdots x_n^0]$

$$x_1^{k+1} = \frac{1}{a_{11}}(b_1 - \sum_{j=2}^{n} a_{1j}x_j^k)$$

$$x_2^{k+1} = \frac{1}{a_{22}}(b_2 - \sum_{j=1, j\neq 2}^{n} a_{2j}x_j^k)$$

$$\cdots$$

$$x_n^{k+1} = \frac{1}{a_{nn}}(b_n - \sum_{j=1}^{n} a_{nj}x_j^k)$$

attention

Si la matrice A ne vérifie pas les conditions de la proposition, on ne peut rien conclure. Ce sont des conditions suffisantes mais pas nécessaires.

Si l'un des coefficients diagonaux est nul, il est parfois possible de permuter certaines lignes pour éviter cette situation.

Exemple

$$\begin{aligned} 3x_1 + x_2 - x_3 &= 2 \\ x_1 + 5x_2 + 2x_3 &= 17 \\ 2x_1 - x_2 - 6x_3 &= -18 \end{aligned}$$

donc

$$x_1^{k+1} = \frac{1}{3}(2 - x_2^k + x_3^k)$$

$$x_2^{k+1} = \frac{1}{5}(17 - x_1^k - 2x_3^k)$$

$$x_3^{k+1} = \frac{1}{-6}(-18 - 2x_1^k + x_2^k)$$

À partir de $[000]^T$, on trouve le tableau de convergence suivant :

k	x_1^k	x_2^k	x_3^k
0	0.000000	0.000000	0.000000
1	0.666667	3.400000	3.000000
2	0.533333	2.066667	2.655556
3	0.862963	2.231111	2.833333
4	0.867407	2.094074	2.915802
5	0.940576	2.060198	2.940123
6	0.959975	2.035835	2.970159
7	0.978108	2.019941	2.980686
8	0.986915	2.012104	2.989379
9	0.992425	2.006865	2.993621

On décompose la matrice A sous la forme $A = D + T_I + T_S$ avec :
D : est une matrice qui contient la diagonal de A et les autres composantes sont nulles.
T_I : est une matrice qui contient le bloc inferieur à la diagonale et les autres composantes sont nulles.
T_I : est une matrice qui contient le bloc supérieur à la diagonale et les autres composantes sont nulles.

$$\begin{aligned} Ax = b \quad & \Rightarrow (D + T_I + T_S)x = b \\ & \Rightarrow Dx = -(T_I + T_S)x + b \\ & \Rightarrow x = -D^{-1}(T_I + T_S)x + D^{-1}b \\ & \Rightarrow x = T_J x + C_J \end{aligned}$$

On note $J = T_J = -D^{-1}(T_I + T_S)$
On a $x^{k+1} = T_J x^k + C_J$ alors la méthode de Jacobi n'est rien d'autre qu'un cas particulier de méthodes de points fixes en dimension donc :
La méthode de Jacobi convergera donc si le rayon spectral de Tj qui est $\rho(Tj)$ est inférieur à 1.

Definition

Une matrice A est dite à diagonale strictement dominante si :
$|a_{ii}| > \sum_{j=1, j\neq i}^{n} |a_{ij}| \qquad \forall i$

Cette définition signifie que le terme diagonal au de la matrice A est nettement dominant puisque sa valeur absolue est plus grande que la somme des valeurs absolues de tous les autres termes de la ligne.
les matrices à diagonale dominante vérifient la condition $\rho(T_j) < 1$.

Theorem

Si A est une matrice à diagonale strictement dominante, la méthode de Jacobi est convergente.

La méthode de Gauss-Seidel est une variante améliorée de la méthode de Jacobi. Pour bien en comprendre le principe, il suffit de reconsidérer la méthode de Jacobi et de voir comment on pourrait l'améliorer. On sait que dans le cas général la méthode de Jacobi s'écrit :

$$x_i^{k+1} = \frac{1}{a_{ii}}(b_i - \sum_{j=1, j\neq i}^{n-1} a_{ij} x_j^k) = \frac{1}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^k - \sum_{j=i+1}^{n} a_{ij} x_j^k)$$

pour le calcul de x_i^{k+1}, on peut utiliser $x_1^{k+1}, \quad x_2^{k+1}, \cdots x_{i-1}^{k+1}$ déjà calculés et les $x_{i+1}^k, \quad x_{i+2}^k, \cdots x_n^k$ de l'itération précédente.

$$x_i^{k+1} = \frac{1}{a_{ii}}(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{k+1} - \sum_{j=i+1}^{n} a_{ij} x_j^k)$$

on aura

$$x^{k+1} = D^{-1}(b - T_I x^{k+1} - T_S x^k)$$

$$(D + T_I)x^{k+1} = b - T_S x^k$$

$$x^{k+1} = -(D + T_I)^{-1} T_S x^k + (D + T_I)^{-1} b$$

$$x^{k+1} = T_{GS} x^k + C_{GS}$$

Exemple

$$\begin{aligned} 3x_1 + x_2 - x_3 &= 2 \\ x_1 + 5x_2 + 2x_3 &= 17 \\ 2x_1 - x_2 - 6x_3 &= -18 \end{aligned}$$

donc

$$x_1^{k+1} = \frac{1}{3}(2 - x_2^k + x_3^k)$$

$$x_2^{k+1} = \frac{1}{5}(17 - x_1^{k+1} - 2x_3^k)$$

$$x_3^{k+1} = \frac{1}{-6}(-18 - 2x_1^{k+1} + x_2^{k+1})$$

Partons de la solution $[0,0,0]^T$, on trouve

$$x_1^1 = \frac{1}{3}(2 - 0 + 0) = \frac{2}{3}$$

$$x_2^{k+1} = \frac{1}{5}(17 - \frac{2}{3} - 0) = \frac{49}{15}$$

$$x_3^{k+1} = \frac{1}{-6}(-18 - 2\frac{2}{3} + \frac{49}{15}) = \frac{241}{90}$$

À partir de $[0,0,0]^T$, on trouve le tableau de convergence suivant :

k	x_1^k	x_2^k	x_3^k
0	0.000000	0.000000	0.000000
1	0.666667	3.266667	2.677778
2	0.4703704	2.234815	2.784321
3	0.8498354	2.116305	2.930561
4	0.9380855	2.040158	2.972669
5	0.9775034	2.015432	2.989929
6	0.9914991	2.005729	2.996212
7	0.9968277	2.002150	2.998584
8	0.9988115	2.000804	2.999470
9	0.9995553	2.000301	2.999802

Theorem

Si la matrice A est à diagonale strictement dominante, le rayon spectral de T_{GS} est inférieur à 1 et la méthode de Gauss-Seidel converge, et ce que quelle que soit la solution initial x^0.

Surprise : les calculs pour la décomposition et la résolution ne seront pas exacts!
Deux sources d'erreurs :

- **Erreurs liées à la représentation** de A et b, Exemple :

$$\begin{pmatrix} 1 & 2 \\ 1.1 & 2 \end{pmatrix}\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 10 \\ 10.4 \end{pmatrix}$$

  La solution exacte est $x = (4, 3)$. Si dans la matrice on prend 1.05 au lieu de 1.1, la solution exacte est $x = (8, 1)$.
  $\rightarrow$ **Mauvaise stabilité** par rapport aux variations des coefficients.
  En pratique l'arithmétique flottante va introduite des perturbations sur la représentation de A et b, qui peuvent donc avoir de grandes répercussions sur la solution.
- **Erreurs liées à la méthode de résolution** et provenant des calculs en arithmétique flottante (ex : divisions et soustractions dangereuses pendant les remontées ou descentes triangulaires).

Solutions partielles pour limiter les erreurs :

- Dans *LU* faire des permutations de lignes pour choisir le plus grand pivot.
- Mettre les lignes à l'échelle, on divise chaque ligne par le plus grand coefficient de la ligne en valeur absolue,

$$a_{ij} \leftarrow \frac{a_{ij}}{\max_j a_{ij}}, \quad i = 1, \ldots, n.$$

Cependant, pas de solutions miracles. On va se définir des outils pour chercher à mesurer ces erreurs. Objectifs :

- Mesurer l'écart entre la solution numérique et la solution exacte,
- Mesurer la sensibilité du système à des perturbations.

Comment mesurer la distance entre deux vecteurs ?

Definition

"Norme vectorielle" Une norme est une application de $\mathbb{R}^n$ dans $\mathbb{R}^+$ qui à $x \in \mathbb{R}^n$ associe $\|x\|$ telle que :

- $\|x\| \geq 0$ et $\|x\| = 0 \Rightarrow x = 0$.
- Si $\alpha \in \mathbb{R}$, $\|\alpha x\| = |\alpha| \|x\|$
- $\|x + y\| \leq \|x\| + \|y\|$

Des exemples de normes :

- Norme 1 : $\|x\|_1 = \sum_{k=1}^{n} |x_k| = |x_1| + |x_2| + \cdots + |x_n|$
- Norme 2 : $\|x\|_2 = \sqrt{\sum_{k=1}^{n} |x_k|^2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$
- Norme infinie : $\|x\|_\infty = \max_k |x_k| = \max\{|x_1|, |x_2|, \ldots, |x_n|\}$

Comment mesurer la distance entre deux matrices ?

Definition

"Norme matricielle" Une norme matricielle est une application de $M_n(\mathbb{R})$ dans $\mathbb{R}^+$ qui à $A \in M_n(\mathbb{R})$ associe $\|A\|$ telle que :

- $\|A\| \geq 0$ et $\|A\| = 0 \Rightarrow A = 0$.
- Si $\alpha \in \mathbb{R}$, $\|\alpha A\| = |\alpha| \|A\|$
- $\|A + B\| \leq \|A\| + \|B\|$
- $\|AB\| \leq \|A\|\|B\|$

Definition

"Norme matricielle induite ou subordonnée" Pour une norme vectorielle donnée $\|\cdot\|_i$, la norme matricielle induite est définie par :

$$\|A\|_i = \sup_{\|x\|_i \neq 0} \frac{\|Ax\|_i}{\|x\|_i} = \sup_{\|x\|_i = 1} \|Ax\|_i$$

Exemples de normes matricielles usuelles :

- La norme matricielle induite par la norme 1 (max sur la somme, en valeurs absolues, par colonne) :

$$\|A\|_1 = \max_{1\leq j\leq n} \sum_{i=1}^{n} \left|a_{ij}\right| = \max_{1\leq j\leq n} \{|a_{1j}| + |a_{2j}| + \cdots + |a_{nj}|\}$$

- La norme matricielle induite par la norme infinie (max sur la somme, en valeurs absolues, par ligne) :

$$\|A\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} \left|a_{ij}\right| = \max_{1\leq i\leq n} \{|a_{i1}| + |a_{i2}| + \cdots + |a_{in}|\}$$

  n a $\|A\|_1 = \left\|A^t\right\|_\infty$, et donc si A symétrique $\|A\|_1 = \|A\|_\infty$

- Norme de Frobenius (norme induite par aucune norme) :

$$\|A\|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n} a_{ij}^2}$$

Definition

"Normes compatibles" Une norme vectorielle $\|\cdot\|_v$ et une norme matricielle $\|\cdot\|_M$ sont compatibles si pour tout $x \in \mathbb{R}^n$ et $A \in M_n(\mathbb{R})$:

$$\|Ax\|_v \leq \|A\|_M \|x\|_v$$

Theorem

"Normes compatibles"

- *Toutes les normes matricielles induites sont compatibles avec leurs normes vectorielles,*

$$\|Ax\|_1 \leq \|A\|_1 \|x\|_1, \quad \|Ax\|_\infty \leq \|A\|_\infty \|x\|_\infty,$$

- *La norme de Frobenius est compatible avec la norme euclidienne,*

$$\|Ax\|_2 \leq \|A\|_F \|x\|_2,$$

En pratique, on utilise souvent la norme 1 ou la norme ∞, car plus simple à calculer.

Erreur absolue et relative pour la résolution de $Ax = b$: Soit x^* la solution numérique et x la solution exacte. Le **vecteur de l'erreur** est défini par

$$e = x - x^*.$$

On souhaite que la norme de ce vecteur, $\|e\|_v$ soit la plus faible possible. Pour chaque x^*, on peut également associé le vecteur

$$r = b - Ax^*.$$

r est appelé **le vecteur résidu**. On a immédiatement

$$r = b - Ax^* = Ax - Ax^* = A(x - x^*) = Ae. \tag{7}$$

En utilisant (7), et en utilisant le fait que les normes sont compatibles, on montre le résultat suivant

proposition

On contrôle l'erreur relative due à l'algorithme de résolution de $Ax = b$ via l'inégalité suivante

$$\frac{1}{\|A\|_M \left\|A^{-1}\right\|_M} \frac{\|r\|_v}{\|b\|_v} \leq \frac{\|e\|_v}{\|x\|_v} \leq \|A\|_M \left\|A^{-1}\right\|_M \frac{\|r\|_v}{\|b\|_v}.$$

La quantité $\|A\|_M \left\|A_M^{-1}\right\|$ permet de mesurer l'effet de la matrice sur la résolution du système et porte un nom particulier

Definition

"Conditionnement" Le conditionnement d'une matrice A inversible pour la norme matricielle $\|\cdot\|_M$ est défini par :

$$cond_M(A) = \|A\|_M \|A^{-1}\|_M$$

- Le conditionnement n'est définie que pour les matrices inversibles,
- Le conditionnement **dépend de la norme choisie**,
- $cond_M(A) \geq 1$,
- **Problème** : le conditionnement fait intervenir A^{-1} qui en règle général est très difficile à calculer.

L'inégalité précédente s'écrit alors

$$\frac{1}{cond_M(A)} \frac{\|r\|_v}{\|b\|_v} \leq \frac{\|e\|_v}{\|x\|_v} \leq cond_M(A) \frac{\|r\|_v}{\|b\|_v}. \tag{8}$$

Concrètement, l'inégalité permet de dire que **dans le pire des cas**, l'erreur relative sera

$$\frac{\|e\|_v}{\|x\|_v} = cond_M(A)\frac{\|r\|_v}{\|b\|_v}.$$

Il est donc préférable que le **conditionnement soit petit**, idéalement $cond_M(A) \approx 1$. Un «grand» conditionnement indique qu'il est possible que l'erreur soit importante.

→ Plus le conditionnement de A est grand, plus on a intérêt à avoir un petit résidu, on devra alors être attentif à la qualité de la méthode de résolution. L'inégalité suppose

que la matrice A et le second membre b sont représentés exactement en machine, ce qui n'est pas le cas! Cela nous amène à **l'erreur de représentation**.

Erreur de représentation : L'analyse est faite seulement sur A, mais le raisonnement est le même sur b.
Soit ΔA la matrice des erreurs de représentation sur A :

$$A^* = A + \Delta A$$

et x^* la solution du système perturbé, $A^* x^* = b$. Alors on a le résultat suivant,

proposition

Soit x^* la solution de $(A + \Delta A)x^* = b$ et x la solution exacte de $Ax = b$

$$\frac{\|x - x^*\|_v}{\|x^*\|_v} = \frac{\|e\|_v}{\|x^*\|_v} \leq cond_M(A) \frac{\|\Delta A\|_M}{\|A\|_M}$$

Que nous dit cette inégalité ?

- Si $cond_M(A)$ est grand, une petite variation de A pourrait résulter en une grande variation sur la solution du système.
- Inversement, si $cond_M(A)$ est petit, une petite variation de A entraîne une petite variation sur la solution du système.

Il reste un point à voir, comment calculer $cond_M(A)$ **sans inverser** A^{-1} ?
En utilisant l'inégalité (8), on obtient **une borne minimale**

$$cond_M(A) \geq \max\left(\frac{\|e\|_v \|b\|_v}{\|r\|_v \|x\|_v}, \frac{\|r\|_v \|x\|_v}{\|e\|_v \|b\|_v}\right)$$

a borne dépend de b, x et de la méthode de résolution, alors que le conditionnement ne dépend que de la matrice A. En pratique, x est inconnu! $\rightarrow$ on se construit un problème.

1. On choisit y quelconque et on calcul $b = Ay$,
2. On calcul y^* avec la méthode de résolution désirée,
3. On calcul $r = b - Ay^*$ et $e = y - y^*$,
4. On calcul le max

Hélas, la borne obtenue dépend du point y choisi arbitrairement, de la méthode de résolution et de la norme choisie. Mais cela donne toujours «une idée» du conditionnement, et c'est le mieux que l'on puisse faire sans calculer A^{-1}.

Conclusion sur le conditionnement :

- On a toujours $cond_M(A) \geq 1$.
- Le conditionnement permet de contrôler l'erreur (relative), il ne dit rien, a priori, sur la valeur de l'erreur relative,
- Un conditionnement petit assure un bon contrôle de l'erreur de notre solution,
- Avoir un petit conditionnement, n'assure pas une erreur relative petite,
- Un conditionnement grand indique qu'il faut être attentif à l'algorithme choisi et aux possibles propagations d'erreurs,
- Un grand conditionnement n'assure pas que l'erreur relative sera grande,
- On évite, en pratique, de calculer A^{-1} pour calculer le conditionnement. On préférera se servir de la borne inférieure trouvée.

Voyons à présent la résolution d'un **système d'équations non linéaires. Notation** :

- Soit $(f_i)_{1\leq i\leq n}$ n fonctions de n variables $(x_1, x_2, \ldots, x_n)$, différentiables,
- On définit pour $x = (x_1, \ldots, x_n) \in \mathbb{R}^n$, $F(x) = (f_1(x), f_2(x), \cdots, f_n(x))$.
- On veut résoudre $F(x) = 0$. On note $r = (r_1, r_2, \ldots, r_n)$ la solution (racine).

En terme de système, cela revient à trouver $x = (x_1, \ldots, x_n)$ tel que :

$$\begin{cases} f_1(x_1, x_2, \cdots, x_n) = 0 \\ f_2(x_1, x_2, \cdots, x_n) = 0 \\ \vdots \\ f_n(x_1, x_2, \cdots, x_n) = 0 \end{cases}$$

Mis à part la méthode de la bissection, les méthodes du chapitre 2 peuvent être adaptées pour résoudre ce système. On présente ici la méthode la plus utilisée : la **méthode de Newton**.

Principe : On part de $x^0 = (x_1^0, x_2^0, \ldots, x_n^0)$ - idéalement proche de la racine - et on cherche une correction $\delta x^0 = (\delta x_1^0, \delta x_2^0, \ldots, \delta x_n^0)$ telle que pour tout i, $f_i(x^0 + \delta x^0) = 0$. Cela nous donne, en réalisant un développement de Taylor à l'ordre 1,

$$\begin{cases} 0 = f_1(x^0 + \delta x^0) \approx f_1(x^0) + \delta x_1^0 \dfrac{\partial f_1}{\partial x_1}(x^0) + \delta x_2^0 \dfrac{\partial f_1}{\partial x_2}(x^0) + \cdots + \delta x_n^0 \dfrac{\partial f_1}{\partial x_n}(x^0) \\ 0 = f_2(x^0 + \delta x^0) \approx f_2(x^0) + \delta x_1^0 \dfrac{\partial f_2}{\partial x_1}(x^0) + \delta x_2^0 \dfrac{\partial f_2}{\partial x_2}(x^0) + \cdots + \delta x_n^0 \dfrac{\partial f_2}{\partial x_n}(x^0) \\ \vdots \\ 0 = f_n(x^0 + \delta x^0) \approx f_n(x^0) + \delta x_1^0 \dfrac{\partial f_n}{\partial x_1}(x^0) + \delta x_2^0 \dfrac{\partial f_n}{\partial x_2}(x^0) + \cdots + \delta x_n^0 \dfrac{\partial f_n}{\partial x_n}(x^0) \end{cases}$$

Soit, sous forme matricielle,

$$\vec{0} = F(x^0) + \begin{pmatrix} \dfrac{\partial f_1}{\partial x_1}(x^0) & \dfrac{\partial f_1}{\partial x_2}(x^0) & \cdots & \dfrac{\partial f_1}{\partial x_n}(x^0) \\ \dfrac{\partial f_2}{\partial x_1}(x^0) & \dfrac{\partial f_2}{\partial x_2}(x^0) & \cdots & \dfrac{\partial f_2}{\partial x_n}(x^0) \\ \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial f_n}{\partial x_1}(x^0) & \dfrac{\partial f_n}{\partial x_2}(x^0) & \cdots & \dfrac{\partial f_n}{\partial x_n}(x^0) \end{pmatrix} \begin{pmatrix} \delta x_1^0 \\ \delta x_2^0 \\ \vdots \\ \delta x_n^0 \end{pmatrix}$$

Definition

"Matrice jacobienne" On note $J(x^i)$, la matrice dite jacobienne définie par

$$J(x^i) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(x^i) & \frac{\partial f_1}{\partial x_2}(x^i) & \dots & \frac{\partial f_1}{\partial x_n}(x^i) \\ \frac{\partial f_2}{\partial x_1}(x^i) & \frac{\partial f_2}{\partial x_2}(x^i) & \dots & \frac{\partial f_2}{\partial x_n}(x^i) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1}(x^i) & \frac{\partial f_n}{\partial x_2}(x^i) & \dots & \frac{\partial f_n}{\partial x_n}(x^i) \end{pmatrix} = \begin{pmatrix} \left(\nabla f_1(x^i)\right)^t \\ \left(\nabla f_2(x^i)\right)^t \\ \vdots \\ \left(\nabla f_n(x^i)\right)^t \end{pmatrix}$$

On cherche alors une correction δx^0 telle que

$$\vec{0} = F(x^0) + J(x^0)\delta x^0 \iff J(x^0)\delta x^0 = -F(x^0)$$

$-F(x^0)$ est appelé le **résidu** en x^0. La résolution de ce système matriciel nous donne la correction $\delta x^0 = -J(x^0)^{-1}F(x^0)$ à apportée à x^0. **On ne calcul pas l'inverse, on**

résout le système ! On recommence ensuite la démarche à partir de $x^1 = x^0 + \delta x^0$.

Algorithme de Newton pour les systèmes :

Data:

- Des fonctions f_i, $1 \leq i \leq n$ deux fois différentiables et un point de départ $x^0 = (x_0, x_1, \ldots, x_n)$. $F(x^0) = (f_1(x^0), \ldots, f_n(x^0))$
- Une tolérance d'arrêt ϵ_a et un nombre max d'itérations n_{max}
- la précision machine ϵ_m.

Result: le vecteur x^{i+1} qui contiendra une approximation de la racine $r = (r_1, \ldots, r_n)$

while $\frac{\|x^{i+1} - x^i\|}{\|x^{i+1}\| + \epsilon_m} > \epsilon_a$ *et* $n \leq n_{max}$ **do**

  Résoudre $J(x^i)\delta x^i = -F(x^i)$;

  $x^{i+1} = x^i + \delta x^i$;

  $i = i + 1$;

end

Algorithm 1: Algorithme de Newton, pseudo-code

Remarques :

- L'inverse de la matrice jacobienne $J_F(x^0)^{-1}$ joue le rôle que jouait $\frac{1}{f'(x_0)}$ en dimension 1,
- À chaque étape, on résout un système linéaire de dimension n. À chaque itération il faut que $J(x^i)$ soit inversible,
- La convergence est quadratique si $J_F(r)$ est inversible. Sinon elle est linéaire (on retrouve le comportement 1D dans le cas des racines multiples),
- Pour étudier la convergence on fera les mêmes tableaux qu'en 1D, en remplaçant les valeurs absolues par des normes vectorielles,
- Il est primordial (plus qu'en 1D) que x^0 soit proche de r sous peine de divergence possible.
- Il faut aussi calculer la matrice jacobienne d'une fonction à plusieurs variables ce qui peut être très fastidieux.

Des variantes :

- **Quasi-Newton :** On ne calcule pas la matrice jacobienne à chaque itération. On garde la même pendant plusieurs itérations (on économise le calcul de dérivées et si factorisation LU utilisée, on réduit le nombre de factorisation).
- **Newton modifiée :** On remplace les dérivées partielles par des approximations précises, pour $h > 0$ petit :

$$\frac{\partial f_i}{\partial x_j}(x) = \frac{f_i(x_1, \cdots, x_j + h, \cdots, x_n) - f_i(x_1, \cdots, x_j - h, \cdots, x_n)}{2h}$$

conclusion

Conclusion Chapitre 4, je dois savoir faire :

- *Je sais faire une méthode d'élimination de Gauss d'un système linéaire et définir les matrices équivalentes aux opérations élémentaires,*
- *Je sais faire une décomposition et une résolution par LU et Cholesky,*
- *Je distingue Doolittle et Crout,*
- *Je sais reconnaître des matrices permettant d'appliquer ou d'exclure Cholesky,*
- *Je comprends la notion de conditionnement d'une matrice,*
- *Je connais le théorème sur le conditionnement,*
- *Je sais appliquer le théorème de conditionnement pour caractériser une solution et son erreur relative,*
- *Je sais construire une borne inférieure du conditionnement et je comprends ses limitations,*
- *Je sais calculer une matrice Jacobienne,*
- *Je sais utiliser la méthode de Newton pour les systèmes non linéaires, et comprend ses limitations et ses variantes.*